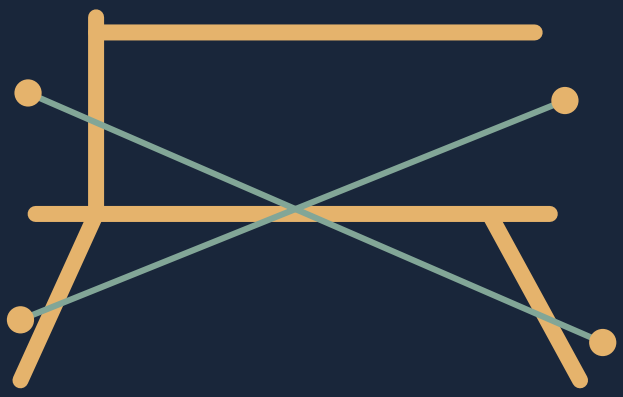
WEEKLY LONG READ · VOL. 05

# 一把椅子，检验了什么？

木工、身体经验，以及 AI 时代“谁在学习”



本周选文

Benchma(r)king

James Bridle · Emergence Magazine · 2026-10-14

2026.10.24

EDITOR'S NOTE

# 本期导读

| | |
|---|---|
| 文章 | Benchma(r)king |
| 作者 | James Bridle |
| 来源 | Emergence Magazine · Essay |
| 日期 | 2026 年 10 月 14 日 |
| 阅读 | 约 25-35 分钟（按全文篇幅估算） |
| 原文 | emergencemagazine.org/essay/benchmarking |

## 为什么值得读

这是一篇把技术问题重新放回生活现场的文章。作者不是让 AI 写一段代码或做一次考试，而是让它根据阳台上的废木料设计一把真正需要承受人体重量的椅子。木头会断，尺寸会失衡，坐上去的人会疼；机器流畅的语言必须接受材料、重力和身体的检验。

文章的妙处在于，它并不满足于得出“AI 会犯错”这个浅结论。作者把椅子连接到测量史、手工教育、家庭危机、设计伦理和权力关系，最终提出更重要的问题：使用工具以后，究竟是谁获得了能力？如果每次输出都像凭空出现的奇迹，人是否会忘记知识来自共同世界、前人经验和亲手试错？

### 本期判断

它最适合在“AI 能替我做什么”的兴奋稍微退潮后阅读。文章提醒我们，真正好的工具关系不只看结果快不快，还要看人是否因此学会观察材料、理解约束，并逐渐减少对工具权威的依赖。

## 版权说明

原文为普通受版权保护内容。本报告不复制全文，也不逐段翻译；主体采用基于理解后的原创中文重述，仅保留一则短摘录及对应翻译。

ARGUMENT MAP

# 一张图读懂文章结构

| | | |
|---|---|---|
| 01 | 尺度 | benchmark 原本是把不同地点接入同一海拔基准的刻痕，强调连接与校准，而非排行榜。 |
| 02 | 处境 | 伴侣重病、城市困居与育儿压力，使木工成为维持身体和精神秩序的一种实践。 |
| 03 | 制作 | 作者让不同 AI 根据有限废料设计椅子，语言输出第一次接受重力、人体和材料的反驳。 |
| 04 | 学习 | Enzo Mari 的自制家具让人通过动手获得判断；AI 椅子却暴露“谁实际学到了东西”的疑问。 |
| 05 | 关系 | 好的智能关系应像会消解自身权威的教师，让使用者更能独立判断，而不是更依赖答案。 |

## 文章如何推进

作者先从十九世纪刻在教堂墙上的水准点写起，把“benchmark”从模型评分表还原为一种与海潮、地貌和共同世界相连的测量方法。随后镜头转到雅典公寓：伴侣住院，作者在照护、育儿与焦虑之间需要用双手做点什么。AI 设计椅子的实验由此出现。

文章中段借意大利设计师 Enzo Mari 的自制家具计划说明：制作不是把图纸准确复制出来，而是在材料反抗和错误修正中发展判断。后半段比较 ChatGPT、Mistral、Claude 与 Grok 设计的不同椅子，把模型缺陷变成可坐、可摇晃、甚至会塌的证据。最后，文章从椅子回到教育和权力：智能的价值不应只是提取和优化，也应包括分享、共处与让他人获得能力。

DEEP READING · I

# 中文重述：排名之前，benchmark 是一条连接线

## 1. 石墙上的小刻痕

文章从 1840 年利物浦的一处教堂外墙开始。测量员在石头上凿出水平线和箭头，用来固定测量杆的位置。后来的人可以回到同一点重新读数，于是这个刻痕成为可重复测量的参照。它不是为了宣布哪座建筑更优，而是让分散地点共享同一高度语言。

英国的全国高程基准后来转向港口的平均海面，并最终移到康沃尔的纽林。海并不是恒定平面，潮汐与长期海平面变化都会让所谓“标准”发生微调。由此得到的第一个重要提醒是：任何基准都不是脱离世界的绝对值，它建立在地点、时间、仪器与共同约定上。

## 2. 从校准工具变成竞争排行榜

今天说起 benchmarking，人们通常想到模型分数、软件性能、成本或增长率。基准被用来切分赢家与输家，仿佛数值越高就越接近真实价值。作者把词源重新召回，是为了指出被遗忘的另一面：原初的 benchmark 用于“找平”和连接，使各处测量能够互相解释。

这个开场为后文设定判断标准。椅子实验并不是为了选出最强模型，而是要让模型的语言与木材、工具、人的身体以及此前所有造物经验发生连接。只有进入这条连续线，输出才不再是孤立的表演。

> 换一种理解
>
> 真正有意义的基准，不只是问“谁得分更高”，还要问“这个分数与什么现实相连、由谁承担误差、能否被别人重新验证”。

## 3. 标准本身也必须接受现实修订

海平面会上升，测量点会消失，卫星系统会取代墙面刻痕。基准的可信度不来自永不改变，而来自它公开自己的参照，使后人能够发现偏差并调整。文章后来对 AI 的要求也是如此：与其制造无来源的权威感，不如把材料、限制和失败留在结果里，让判断可以继续。

DEEP READING · II

# 中文重述：在生活失去尺度时，用双手做一件东西

## 4. 实验并非从技术好奇开始

作者原本和家人住在希腊小岛，拥有空间，也开始建造自己的房屋。2023 年底，伴侣 Navine 严重生病，一家人不得不返回雅典；她住院九个月，作者每天探视，同时照顾三岁的孩子。生活被医院、幼儿园、睡眠和再次出发切成循环。

在这种处境中，做椅子不是悠闲的创客项目。作者缺少空间、工具和稳定时间，却迫切需要一件能让身体与精神保持运转的事情。制作提供了明确的物理反馈：木板长度有限，螺丝是否咬合，结构能否站立。与疾病的不确定相比，这些限制虽然顽固，却可以触摸。

## 5. 为什么偏偏让 AI 来参与

作者早年学过人工智能，对这一领域既熟悉又怀疑。他认为近年的爆发与其说来自突然出现的新思想，不如说来自算力、数据和平台权力的集中。他反感 AI 被用于侵占创作、扩大资源消耗和扰乱信息环境，却仍想知道：如果不让机器夺走最有意义的部分，它能否成为真正有用的搭档？

他选择了计算机擅长的优化：在给定材料和功能约束下，用更少废料提出人类未必会想到的结构。同时，他为关系划出边界：机器可以算、可以建议，但打磨、试装、感受重量和修正细节应留给人。理想角色不是老板，也不是替代者，而是木匠身边的助手。

## 6. 阳台上的有限材料

实验条件非常具体：几块旧胶合板、松木板、刨花板、木销和梁料，加上一把锯、钻、螺丝与木胶。作者把尺寸和数量交给 GPT-4，请它根据现有材料设计椅子。有限性不是缺陷，而是实验的核心；只有资源边界足够清楚，所谓“优化”才有可以检验的意义。

### 生活层面的含义

当人生充满无法掌控的事情，制作一件具体物品未必解决危机，却能重建局部尺度：今天切好一块木板、修正一个连接、确认某物能够承重。

DEEP READING · III

# 中文重述：做椅子，是为了学会不只照着做

## 7. Enzo Mari 的反工业设计教育

作者回忆自己真正的椅子老师 Enzo Mari。Mari 在意大利工业设计黄金时期成名，却越来越不满商品把“设计”变成身份符号。他认为，当消费者只购买完成品，就会失去理解物品用途、材料和劳动的能力。于是他转向一种看似倒退的方案：让普通人用木板、钉子和基本工具亲手制作家具。

1970 年代的 Autoprogettazione 计划提供了简陋图纸与成品照片，但其真正目的不是让所有人复制同一把椅子。Mari 希望人们从制作中理解受力、节省材料和结构原则，再根据实际需要发展自己的版本。图纸只是起点，教育的结果应当是使用者不再完全依赖图纸。

## 8. 错误不是执行失败，而是知识出现的地方

作者和朋友曾按这些说明为工作室做桌椅。他们折断钻头，使用了太短或太细的螺丝，打出多余的孔；成品笨重、吱响、需要坐垫，有时还会散架。但正是这些失败教会他们怎样补强、怎样利用边角料、怎样把一个设计改造成适合自身空间的家具。

这种学习无法被压缩为“拿到正确答案”。人在木材的纤维、工具的反作用力、身体重量和朋友协作中获得判断。成品的缺陷没有让过程失去价值，反而留下可维修、可重组的开放性。

## 9. 自我设计的真正目标

Mari 对自己的计划并不乐观，因为很多人仍把说明书当成权威，只求复刻标准答案。作者则强调，他们后来做了长凳、书桌、搁架和厨房单元，逐渐离开原始图纸。这才接近“自我设计”：不是从零发明，而是通过借用前人方法，发展出能够面对新情境的判断。

> 学习判断
>
> 好的教程不会让你永远更擅长照着教程做；它应该让你逐渐知道何时需要偏离教程，以及为什么。

DEEP READING · IV

# 中文重述：一把从未被坐过的“椅子观念”

## 10. ChatGPT 的第一把椅子

作者经过多轮沟通，才让模型理解必须节省现有材料。他从铅笔草图开始，按建议切割并组装。成品第一个意外是座面薄得令人不安：作者本想叠两层胶合板，最终决定相信建议。坐下时木板会轻微弯曲，却真的承住了重量。这种超出个人保守直觉的选择，正是他期待的优化价值。

第二个意外是尺寸。椅子没有大到不能使用，六英尺高的人甚至坐得舒服，但整体比例异常，接近某种不安的陌生感。模型掌握椅子的定义、结构、常见尺寸和物理知识，却没有在房间里与椅子共同生活过，也没有身体记忆告诉它某种比例为什么看起来不对。

短摘录

“a chair designed by someone who has read a lot about chairs but never actually sat in one”
中文：一把由读过许多椅子知识、却从未真正坐过椅子的存在所设计的椅子。

原文短摘录，仅用于评论与导读。

## 11. 观念正确，不等于事物成立

这把椅子像“椅子的观念”被直接变成物体。它知道功能名词，却不知道物品如何进入家庭、如何与桌子和身体相处、如何在日常里被靠近和避开。作者借这个低风险案例指出：对象、生命与关系都不只是可描述的观念。书面知识可以覆盖很多方面，却无法自动获得处境中的触感。

## 12. 身体把语言拉回地面

在聊天界面中，模型的建议只需语法连贯；在木工中，建议必须承重。结构不合适就会摇晃，长度算错就无法拼接，人体工学失衡就让脚悬空。材料世界不会因为表达自信而让步，它提供了一种比“看起来合理”更强的检验。

作者没有因此宣布机器毫无价值。薄座面确实带来启发，怪异尺寸也产生审美张力。真正需要拒绝的是把局部成功扩大成普遍权威：一把椅子尚可由人补救，治理社会、文化或生态若忽略身体经验，后果就不再低风险。

DEEP READING · V

# 中文重述：把模型差异做成能坐、会摇晃的证据

## 13. Mistral、Claude 与 Grok 的椅子

作者后来让更多模型参与。Mistral 给出的设计需要大量额外支撑才勉强站立，所谓节省因补强而消失；成品高度夸张，坐下后双脚无法触地，却意外像一件大胆的欧洲设计。东京展览让 Claude 设计椅子，最终成品不错，但精细做工反而让作者怀疑现场是否有熟练木匠大量介入。

Grok 的方案提供了精确切割尺寸，零件却根本无法拼合。团队只能大幅修改，最后得到的物品既是家具，也是失败记录。不同模型的倾向、偏差和能力不再藏在抽象得分里，而以尺寸、接缝、重心和舒适度的形式出现，任何人都可以观察。

## 14. 为什么这是更诚实的 benchmark

常见评测把任务封闭成统一题目，用单一分数比较模型。椅子实验没有如此干净：材料不同，参与者能力不同，修正程度也不同，因此不能产生漂亮排行榜。但它保留了过程和上下文，使人能够追问模型在哪些地方有效、哪些错误由人弥补、成品为何成立。

作者把这种方法称作既是 benchmarking，也是 benchmaking：一边检验，一边真正制作能坐的东西。双关不是玩笑装饰，而是观点本身。只有把智能放进共同世界，它的能力与局限才不再只是企业口径或演示画面。

## 15. 每把椅子都是证据，不是最终判决

物理成品把一次互动固定下来，便于比较和反思，但作者并未声称它能代表模型全部能力。椅子是一个局部、具体、可复现程度有限的证据。好的判断不要求它变成总排名，而是从证据中理解关系：输入怎样塑造输出，人类修改占多大比重，身体和环境纠正了哪些盲点。

> 评测原则
>
> 不要只记录模型最后交付了什么，也记录人为了让结果成立做了什么。被隐藏的人类修补，往往正是系统可靠性的真实来源。

DEEP READING · VI

# 中文重述：最后究竟是谁学会了什么

## 16. 做完以后，人是否变得更有能力

作者喜欢一种学习过程：开始时不会，结束时不仅完成了事情，而且能看见成果，并拥有下一次独立完成的能力。用 Mari 的图纸做家具大体如此；每次错误都沉淀成新的手感和判断。AI 椅子却带来更复杂的结论：实验让作者理解了 AI，但没有显著提高他的木工能力。

模型提供的错误方案之所以最终站得住，是因为作者把此前从人、材料和失败中学到的经验拿来修补。换句话说，他更像教师，而机器像不断获得上下文的学生。如果把这种关系误写成“AI 完成了椅子”，就会把关键知识从叙事中删除。

## 17. 会消解自身权威的教师

文章借 David Graeber 对权威的思考提出标准：教师拥有知识，因此在一段时间内具备合理权威；但好教师的目标，是让学生掌握这些知识，最终不再需要原来的不平等关系。权威若不断制造依赖、扩张自己的必要性，就背离了教育。

用这一标准看 AI，问题不只是它能否给出答案，而是交互后使用者是否更能判断。一个系统如果总以完美、无来源的口吻呈现结果，让人越来越难解释和复核，它就积累权威；如果它公开限制、帮助比较方案、鼓励亲自验证，并让人逐渐掌握方法，它才接近“自我消解”的教师。

## 18. 智能不是支配，而是共处能力

文章最终把智能从性能概念扩展为关系概念。真正值得追求的不只是更强的提取、预测和控制，而是不同智能能否分享知识、共同存在，并在资源有限的世界里一起繁荣。技术难题固然重要，但更难的问题是选择一种不会把人、其他生命和环境都降为原料的关系。

因此，椅子并不是对模型的搞笑考试。它是一种世界选择：要求数字系统接受身体与材料的校准，要求使用者保留手艺与责任，也要求我们判断每一次便利交换之后，谁获得能力、谁承担代价、谁被排除在“进步”之外。

CRITICAL NOTES

# 我赞同什么，又保留什么

## 我赞同：把 AI 输出接入可反驳的现实

模型在语言空间里很容易显得无所不能。让输出接受测试、材料、用户行为或生产数据的反驳，是比继续优化提示词更根本的做法。椅子会不会塌、SQL 会不会锁表、Agent 会不会完成任务，都比回答是否顺滑更重要。

## 我赞同：评估工具时必须检查能力流向

效率提升可能同时伴随学习机会减少。如果工具每次直接交付成品，人获得的是结果，却未必获得理解。文章提供了一个比“节省多少时间”更好的问题：连续这样工作一年后，我会更能独立判断，还是更依赖工具替我判断？

## 我保留：身体经验不是天然正确

亲手制作能产生重要知识，但经验也可能局部、保守或受偏见影响。工程史上的许多进步，恰恰来自数学模型和仪器纠正直觉。文章最有力的版本不应是“身体胜过计算”，而应是让形式知识、身体经验和实证反馈相互校正。

## 我保留：一次物理实验不能代表模型全貌

模型版本、提示方式、参与者技能和材料条件都会改变结果。椅子实验适合揭示盲点，不适合得出普遍性能排序。作者其实也通过“每把椅子是一件证据”避免了过度推广；读者仍应警惕把生动案例误当完整结论。

### 更完整的判断框架

结果：东西是否真的可用？
过程：人做了多少隐形修补？
学习：使用后谁获得了可迁移能力？
权力：工具是否让自身更不可替代？
世界：资源、身体与他人的代价是否被计入？

YOUR LIFE & WORK

# 它与你的工作和生活有什么关系

## 1. SQL 审核：让规则与生产现实接上

静态规则和模型建议像椅子图纸，只描述“通常应该怎样”。真正可靠的审核需要接入表规模、索引选择性、参数分布、锁等待、业务峰值和历史故障。不要只统计模型命中多少规则，还要记录 DBA 做了哪些修正、哪些风险只能靠环境上下文发现。

## 2. Agent 假死：心跳不是承重测试

Agent 持续写心跳，只能证明某条代码路径仍在运行，不能证明任务在推进。这就像一把椅子外形正确，却没有真正坐过。更有效的 benchmark 应包含任务领取、阶段回执、输出进度、截止时间和超时回收，让“活着”与“能完成工作”接受不同证据检验。

## 3. AI 学习：保留自己动手的摩擦

如果每次学习都直接让 AI 生成完整答案，你可能积累了很多看过的内容，却没有形成判断。可以把流程改成：先自己写出问题模型和初步方案，再让 AI 挑错；最后关闭答案，独立重建核心逻辑。把工具放在反馈环，而不是替代环。

## 4. 职业转型：不要只做纸面上的理想人生

副业或新方向也需要“坐上去”的检验。与其继续比较赛道、收益和趋势，不如做出最小成品：一次真实服务、一篇公开作品、一笔小额成交或一个周末项目。现实反馈可能不漂亮，却会告诉你自己是否愿意承受这条路的日常材料。

## 5. 生活中的小型制作

文章也在提醒一种不以展示和效率为目标的活动价值。做饭、修理、整理、训练、写字或搭建个人知识库，都能让抽象愿望进入材料限制。成品未必专业，但制作过程会留下“我知道它为什么这样”的所有权。

### 本周可做

选一件平时会让 AI 直接完成的事，改成“共同制作”：让它给出三个方案和风险，你亲自选择、执行并记录修正。完成后只问一件事：下次没有 AI，我比开始前多会了什么？

REFLECTION

# 五个值得慢慢想的问题

01 你现在用来评价自己、工作或生活的“基准”是什么？它是在帮助校准现实，还是只把你放进排行榜？

02 最近一次 AI 交付看似完整结果时，你做了哪些没有被记录的人类修补？这些修补包含什么隐性知识？

03 有哪些能力，你真正想保留的是亲手完成的过程，而不只是更快拿到结果？

04 一项工具使用一年后，怎样的证据能证明你变得更有判断力，而不是更依赖它？

05 如果把职业或人生计划做成一把必须坐上去的椅子，最先接受现实检验的部分会是什么？

## 值得记住的五句话（中文概括）

基准最初不是为了制造赢家，而是让分散的测量重新接入同一个世界。

语言可以假装理解，材料和身体却会要求它真正承重。

好的说明书教人离开说明书；好的工具也应减少对工具的依赖。

评估 AI 时，人类为了让结果成立所做的修补必须被计入。

智能不只意味着更强的优化能力，也意味着分享、共处和让彼此成长。

ARCHIVE PAGE

# 一页长期保存摘要

## 核心命题

AI 的真正测试，不是它能否生成看似正确的答案，而是答案进入共同世界后能否承受材料、身体与责任的检验；更进一步，还要看使用之后究竟是谁学会了什么。

## 文章的五步逻辑

benchmark 原本是连接不同地点的校准点，而非单纯排行榜。

作者在家庭危机中借木工重建局部秩序，并尝试让 AI 成为助手。

Enzo Mari 的自制家具说明，制作的价值是发展超越图纸的判断。

不同 AI 椅子把抽象模型差异变成可触摸、可承重的证据。

好工具应像会消解自身权威的教师，使使用者逐渐更能独立判断。

## 最实用的转换

把“AI 完成了什么”改成三问：结果经过了什么现实检验？人做了多少隐藏修补？下次没有 AI，人是否比以前更有能力？

## 保留意见

身体经验与手艺很重要，但并非天然正确；数学模型、仪器和可重复实验同样能纠正直觉。真正可靠的工作方式，是让抽象知识、身体经验和环境反馈形成闭环。

## 一句话带走

> 留存句
>
> 不要只问一把椅子是谁设计的；要问坐下去之前，谁知道它为什么不会塌。

## 适合什么时候重读

当你被新的模型排行吸引时；当 AI 交付越来越快、自己却越来越难解释过程时；当你计划转型却迟迟没有让想法接受真实用户和现实成本检验时。

SOURCES

# 信息来源与编辑说明

## 主要来源

1. Emergence Magazine, “Benchma(r)king”, James Bridle, 2026-10-14。阅读全文

页面明确标注作者、日期与 Essay 类型；全文无需登录即可阅读。本报告按文章整体推进进行原创中文重述，没有重现全文。

## 来源背景

2. Emergence Magazine, About。媒体介绍

用于核验该刊以生态、文化与精神生活为主题，长期刊发深度文章及音频故事。

## 编辑方法

检索范围为 2026 年 10 月 10 日至 10 月 24 日。选文优先考虑免费完整可读、20-40 分钟、文学随笔或人生思考方向，并避开近期已选的 Aeon、The Point 及“人生叙事/注意力”相近主题。阅读时长由正文篇幅与一般英文深度阅读速度估算，网站未提供官方阅读时长。

“中文重述版 / 深度导读”按原文论证顺序重组，但不是逐句翻译或段落镜像。本报告加入的章节标题、批判性判断、工作关联、实践框架与问题均为编辑性分析，应与作者本人观点区分。

## 版权边界

原文版权归作者与 Emergence Magazine 所有。本报告仅保留一则短摘录，其他内容均为非替代性的概括、评论与延伸思考。若需要完整语气、图像与文学表达，请访问原文。